Milestone 3 — Reference Matching Pipeline

Người làm M3 đọc file này trước khi mở code.

Đề đầy đủ: https://hcmus-cs-ta.github.io/lab-book/intro-ds/statement/matching

Phụ thuộc: M1 có bảng `references` (ref **có arXiv ID**), M2 có bảng `bibtex` (+ hierarchy nếu dùng feature ngữ cảnh).

Bạn đang làm gì?

Với **cùng một paper**, ghép mỗi entry BibTeX (M2) với crawled reference (M1).

- Trong 1 paper: `m` bib entries × `n` refs có arXiv ID = ma trận 0/1.
- Mỗi entry labeled: **tối đa 1** ô "yes"; không khớp ref nào → hàng toàn 0.
- Model trả **top 5** `ref_arxiv_id`. Metric: **MRR@5**.
- Cuối cùng xuất **6 bảng Parquet** lên Hugging Face (papers, references, elements, hierarchy, bibtex, predictions).

Chạy:

```
python -m src.m3_matching.run_m3
```

Thứ tự nên code

```
cleaning.py      → chuẩn hóa title/author/year
labelling.py     → ground truth (manual + auto) + kiểm quota
features.py      → vector cặp (bib, ref) — nhớ viết lý do từng feature
split.py         → chia THEO PAPER, không theo từng entry
model.py         → train + predict_top5
evaluate.py      → MRR@5
tables.py        → PredictionRow
pipeline.py      → nối
export_hf.py     → Parquet + README YAML
analyze.py       → số poster
```

Labelling — đọc kỹ, dễ thiếu điểm

Ghép **trong cùng publication** thôi (bib của paper A không khớp ref của paper B).

Manual (người gán):

- ≥ **5** publications
- Mỗi paper manual ≥ **20** entry đã gán

- Tổng entry đã gán (manual pool) ≥ **100**

Auto (regex / similarity, code trong `auto_match_one`):

- ≥ **10%** số publication **ngoài** nhóm manual
- Paper được chọn auto: phải gán **mọi** BibTeX entry của paper đó

File (không commit nếu chứa data lớn; format bắt buộc ghi rõ — đã chốt):

`data/labels/{arxiv_id}.jsonl`

```
{"citation_key": "vaswani2017", "groundtruth_arxiv_id": "1706.03762", "source":
"manual"}
{"citation_key": "someBook", "groundtruth_arxiv_id": null, "source": "auto"}
```

- `source`: chỉ `manual` hoặc `auto`
- `groundtruth_arxiv_id`: arXiv ID của ref đúng, hoặc `null` nếu không có trong crawled refs

---

Split (theo publication)

Tập	Gồm
test	1 paper **manual** + 1 paper **auto**
valid	1 paper **manual** + 1 paper **auto**
train	mọi paper labeled còn lại

Chỉ paper nằm trong 3 tập này mới có hàng ở bảng `predictions`. Paper unlabeled → không xuất.

Metric MRR@5 (test, 2 papers ở trên)

$$\text{MRR@5} = \frac{1}{|Q|} \sum_{i} \frac{1}{\text{rank}_i}$$

- $|Q|$ = số BibTeX **đã label** trên test
- `rank_i` = vị trí GT trong top-5 (`cand_1` = hạng 1)
- GT không nằm top-5, hoặc GT = `null` → điểm entry đó = **0**

Được phép post-process (lọc trùng candidate, boost DOI exact, ...).

Nhóm dùng LLM / pretrained model sẽ bị chấm **tách** nhóm chỉ dùng model cổ điển — ghi rõ trên poster.

Từng file / từng hàm

`cleaning.py`

Hàm	Code cái gì
`normalize_title`	lower, bỏ punct dư, optional stopword — ghi poster vì sao
`normalize_authors`	`Vaswani, Ashish` vs `Ashish Vaswani` → cùng dạng (last name + initials)
`normalize_year`	int / `"2017"` / ISO → `int` hoặc `None`
`prepare_bibtex_record` / `prepare_reference_record`	Thêm field `*_norm`, **không** sửa bảng gốc

`labelling.py`

Hàm	Code cái gì
`auto_match_one`	Heuristic: DOI → title giống → fuzzy (rapidfuzz) + overlap author. Chỉ refs **cùng** paper. Trả `ref_arxiv_id` hoặc `None`
`auto_label_publication`	Chạy matcher cho **mọi** bib entry của 1 paper
`load_labels` / `save_labels`	jsonl như trên
`validate_label_quota`	Raise nếu thiếu 5 papers / 20 / 100 / 10% auto

`features.py` — bắt buộc giải thích từng feature (README + poster)

Được dùng **hierarchy M2** (câu chứa `\cite{key}`, heading gần nhất, số lần cite).

Hàm	Code cái gì
`title_similarity`	0..1 (Levenshtein / Jaccard / TF-IDF cosine)
`author_overlap`	Jaccard last names
`year_distance`	`abs(y1-y2)`; thiếu năm → sentinel, ghi rõ
`cite_context_features`	Optional từ cây M2
`pair_feature_vector`	Ghép thành list[float] **cố định**
`feature_names`	Tên cột **khớp** vector — đừng lệch

Gợi ý tối thiểu (phải viết "ý tưởng" khi implement): title giống nhau thường cùng paper; author overlap giảm false positive cùng title; year loại bản preprint lệch thập kỷ.

`split.py`

`split_publications` → `dict[arxiv_id, "train"|"valid"|"test"]`. Tách manual/auto theo field `source`. `seed` để reproduce.

`model.py`

Paradigm do nhóm chọn (classification cặp / ranking / ...) — ghi poster.

Hàm	Code cái gì
`build_candidate_matrix`	keys, ref ids, matrix 0/1; GT không có trong refs → hàng 0
`train_model`	X,y từ `pair_feature_vector`; sklearn; lưu `data/tables/model_m3.joblib` (gitignore)
`predict_top5`	Score mọi ref cùng paper, sort, cắt 5, pad `None` nếu `n<5`

`evaluate.py`

Hàm	Code cái gì
`reciprocal_rank`	`1/rank` hoặc `0`
`mrr_at_k`	Trung bình trên `
`evaluate_split`	MRR@5 (+ optional hit@1/@5) → nhét `metrics_m3.json`

`tables.py`

`build_prediction_row`: pad/cắt đúng `cand_1`...`cand_5`.
`write_predictions_table`: `data/tables/predictions.jsonl`.

Cột: `arxiv_id`, `partition`, `citation_key`, `groundtruth_arxiv_id` (nullable), `cand_1`...`cand_5` (nullable).

`export_hf.py` — nộp data cuối

```
data/hf_dataset/README.md          # YAML configs, KHÔNG custom loading script
data/hf_dataset/data/papers/*.parquet
data/hf_dataset/data/references/*.parquet
data/hf_dataset/data/elements/*.parquet
data/hf_dataset/data/hierarchy/*.parquet
data/hf_dataset/data/bibtex/*.parquet
data/hf_dataset/data/predictions/*.parquet
```

Card YAML (mỗi bảng một `config_name`, `path: data/<tên>/*.parquet`, `split: train`).
Cột phẳng. Upload Hub theo hướng dẫn Lab Instructors (M3 mới nộp dataset).

`pipeline.py` / `run_m3.py` / `analyze.py`

`run_milestone3`: label → split/train → predict mọi labeled entry → MRR test → ghi predictions → export HF.
`--export-only`: chỉ đóng gói parquet nếu tables đã có.

Việc **không** làm ở M3

- Không đổi schema 6 bảng.
- Không nhét nested JSON vào Parquet.

- Không đưa paper unlabeled vào `predictions`.
- Poster A2 + Jupyter Book = việc nhóm khác / file khác, không nằm trong stub này.

Xong M3 khi nào?

- [ ] `validate_label_quota` pass
- [ ] Split đúng 1+1 test, 1+1 valid
- [ ] Mỗi labeled entry có đúng 1 GT hoặc `null`
- [ ] Test in ra MRR@5
- [ ] 6 thư mục parquet + dataset card YAML
- [ ] Poster/README liệt kê **từng feature và lý do**